端侧 AI 推理性能优化与 seekdb 混合检索

阶跃星辰赛题 · 端侧知识库（stepfun/） · bge-small-zh-v1.5 · Transformers.js + ONNX Runtime Web · seekdb 1.4.0

方案

浏览器 Web Worker 内完成文档/查询向量化：优先 **WebGPU + FP16**，申请 adapter 或热身推理失败即自动降级 **WASM + INT8**，界面标注后端与原因。Node API 通过 seekdb-js 将 id、原文、512 维向量、元数据写入 collection；检索调用一次 **hybridSearch**：`$contains` 走 ngram 全文、`knn` 走 HNSW cosine、`rank.rrf` 在数据库内融合，客户端不拼合两路结果。稳定块 ID + upsert 保证幂等，批量写入后统一 refresh_index。

量化与质量

模型	体积	压缩比	Recall@5	nDCG@5	相对 FP32
FP32 基线	90.5 MB	1.00×	0.9653	0.9012	—
FP16（WebGPU）	45.3 MB	2.00×	0.9653	0.9012	0.00 pp
INT8（WASM）	22.9 MB	3.95×	0.9444	0.8999	−2.08 / −0.13 pp

评测集 24 条中文查询、12 篇文档 / 26 个块；文档级 Recall@5 / nDCG@5，取每个文档最高分块；与线上相同的切分、tokenizer 与 CLS+L2 归一化。

性能（Windows 11 / 32 核 / Edge 156 headless / 12 篇 26 块）

3.8×
WebGPU 批量向量化加速（26 块）

18.2 ms
WebGPU 端到端查询中位数

20.0 ms
WASM 端到端查询中位数

3.95×
INT8 模型压缩比

指标	WebGPU + FP16	WASM + INT8
模型加载（含 tokenizer + 热身）	1.33 s	0.66 s
文档向量化（26 块，batch=8）	277.7 ms（93.6 块/s）	1064.7 ms（24.4 块/s）
seekdb 写入 / 索引刷新	87.1 / 628.7 ms	137.5 / 663.2 ms
查询向量化（中位数）	10.40 ms	5.95 ms
seekdb 混合检索（中位数）	5.38 ms	8.80 ms
端到端查询（中位数 / P95）	18.15 / 21.19 ms	20.01 / 23.00 ms

结论：WebGPU 的收益集中在批量文档向量化（约 3.8×）；batch=1 时 WASM + INT8 并不慢，查询优化应聚焦模型缓存、Worker 预热、单条 batch 与把检索下推到数据库，而不是盲目切 GPU。首次导入后的首查有 60–83 ms 冷启动，预热后稳定在约 20 ms。

工程优化

- 导入 batch=8、查询 batch=1；模型与 ORT WASM 全部本地化，运行时不依赖 CDN。
- 26 条向量按 32 条一批写入，整批结束只调用一次 refresh_index。
- Web Worker 隔离推理；COOP/COEP + crossOriginIsolated 时启用 4 线程 WASM。
- 内置分阶段计时面板，报告 P50/P95，区分首次加载与预热后性能。
- seekdb 本地 server 模式（TCP）跨 Windows/Linux/macOS；数据落在本地 .data/seekdb。

复现：npm install && npm run dev；质量：npm run eval:quality；基准：npm run bench:browser -- -- backend=webgpu / --hide-gpu=true

数据：bench/summary.json · quality.json · model-manifest.json